

Cahier des charges de la mise en place d'un système de prédiction culturelle

OBJECTIF DU STAGE

L'objectif de ce cas d'usage est la mise en place d'un système de prédiction culturale. Vous trouverez dans le document ci-dessous une description de l'existant ainsi que la solution cible à mettre en place. **La date de remise du projet est le XX.** Tous les projets reçus après ce délai ne seront pas pris en compte.

PRESENTATION DU CONTEXTE

Une société distributrice de semences de grandes cultures et de conseil et commerce autour de l'agriculture française à rayonnement Européen et leader dans le monde de l'agriculture souhaite conserver et accroître sa position en réalisant des innovations technologiques dans ce secteur.

Cette société dispose d'un pôle important de Recherche et Développement constitué de plus de 300 personnes et génère de nombreuses données issues, de conditions culturales, de lignées, d'études génomiques et de génotypage des plantes. La direction souhaite mettre en relation l'ensemble de ces données et proposer aux différents métiers de la société une plateforme BIG DATA innovante pour répondre aux objectifs du groupe.

Dans ce contexte, le pôle Recherche et Développement a mis à notre disposition plusieurs fichiers sources s'appuyant sur la conduite culturale et l'analyse génétique de plusieurs espèces. Il souhaite accéder à toutes ces données en utilisant des indicateurs et des tableaux de bord pour réaliser des prises de décision stratégiques futures. L'un des impératifs demandés par le pôle R&D est de pouvoir accéder aux données statistiques par l'intermédiaire de R.

Ultérieurement des données météorologiques et des mesures réalisées par des drones seront également envisagées.

DE LA MISSION

Le besoin exprimé par la société distributrice de semences est de mettre en place une solution capable de :

- Dé-siloter les données et les centraliser dans un entrepôt unique, quelle que soit leur origine (interne ou externe à la société) ou leur format (hétérogènes).
- Permettre de gérer de façon plus agile la mise en place de couches de données et de pouvoir les faire évoluer (brutes, transformées, enrichies, exposées vers d'autres systèmes).
- Mettre à disposition des sélectionneurs et les chercheurs de la société les outils et la puissance de calcul leur permettant de réaliser efficacement leurs activités.
- Mettre en place une démarche forte de qualité, traçabilité et gouvernance de la donnée s'appuyant sur un monitoring technique et fonctionnel des activités de production.

L'architecture devra être nécessairement évolutive.

Plusieurs points doivent être abordés :

- 1. Choix de la plateforme Big Data (Hadoop, Mapr, Cloudera, HortonWorks)**
 - Choix des outils de chargement et de mise à disposition des données (Talend, Nifi, Sqoop ...)

- Choix Base de données Nosql ou du moteur de recherche des données (Hbase, Cassandra, MapR-DB, ...)
- Choix du bus de données (Kafka, MapR-Streams, Talend ESB, ...)
- Mise en place des outils d'analyses et de visualisation (DRILL, Hive, R, Spark, Spotfire, Tableau, ...)

2. Modèle des données

- Structuration des méta-informations des données stockées
- Moteur de recherche de l'information
- Etc,

3. Gestion des flux

- Administration de la plateforme
- Mise en œuvre de chargement de nouveaux flux
- Mise en œuvre de nouveaux flux de mise à disposition de données pour traitement

4. Analyse des données

- Génération du reporting
- Génération des graphes / géolocalisation